

Render Service - Migración a Modal + S3 (MVP)

Fecha: 2026-01-31

Resumen

Se migró el servicio de render (FastAPI + FFmpeg) a Modal para ejecución on-demand, render asíncrono real fuera del request HTTP, y subida del output a Amazon S3 con URL de descarga.

Features implementadas

- **API compatible (mismos endpoints)**

Se mantuvo el mismo contrato: el frontend llama a un endpoint para crear el render y a otro para consultar el estado.

- **Render asíncrono real (no bloquea el request)**

Cuando el usuario aprieta "Generar", el servidor responde rápido con un ID y el render se hace en segundo plano.

- **Worker separado para renders pesados (FFmpeg)**

El trabajo pesado corre en un proceso aislado, para que el API no se caiga por consumo de CPU/RAM.

- **Máximo 4 renders simultáneos**

Aunque entren 20 requests, se procesan 4 a la vez; los demás quedan en cola hasta que haya capacidad.

- **Descarga de assets por URL antes del render**

Imágenes, audios y videos se bajan automáticamente desde sus links antes de ejecutar FFmpeg.

- **Control de threads de FFmpeg**

Se limita el uso de CPU por render (threads=1 en Modal) para evitar que varios renders se "peleen" el servidor.

- **Estado por jobId persistente**

Cada render tiene un ID; puedes ver si está en cola, procesando, listo o falló, y ver el error si aplica.

- **Subida automática del MP4 a S3**

El video final se guarda en el bucket del cliente, evitando depender del disco del servidor.

- **Link de descarga (presigned) por 24 horas**

Al terminar, se entrega un link temporal para descargar el MP4 sin exponer el bucket públicamente.

Mejoras y hardening

- Se corrigieron problemas de packaging/mount en Modal para asegurar imports consistentes del paquete app/.
- Se incorporaron dependencias faltantes del runtime Modal (pydantic-settings, python-dotenv, boto3).
- Se dejó README con comandos de deploy y smoke tests (incluye test de concurrencia).

Notas operacionales

Credenciales AWS se manejan mediante Modal Secret (render-s3). No se incluyen secretos en el repositorio.

Cotización

Cliente: Patricio (Pato)

Servicio: Implementación MVP Render Service en Modal + S3

Ítem	Detalle	Monto (CLP)
Clase inicial (1h)	Revisión de requerimientos, alcance, riesgos y plan	\$40.000
Seteo de ambiente y código	Rama, venv, dependencias, base de deploy	\$30.000
Investigación de solución	Diseño Modal + límites + storage S3 + presign	\$30.000
Desarrollo (2h)	Implementación API + worker + S3 + fixes	\$100.000
Testing y entrega	Smoke tests, validación y handoff	\$30.000
TOTAL		\$200.000

Notas: No incluye optimizaciones avanzadas de performance/calidad, observabilidad avanzada, ni soporte continuo. Presigned URL configurada a 24 horas.